

MINERAÇÃO DE DADOS

Análise de Domicílios por Número de Moradores no Brasil e no Estado de São Paulo (anos 2022 e 2025).

Integrantes:

Debora Rubio

Anecy Otta

Maio/2026

1. Introdução:

Nos últimos anos, o Brasil vem passando por diversas mudanças demográficas e sociais. Uma dessas mudanças está relacionada à quantidade de pessoas que vivem em cada domicílio.

- Reportagem G1-Rede Globo do dia 17/04/2026 (4min20s):

<https://g1.globo.com/jornal-hoje/video/quase-um-em-cada-cinco-domicilios-do-pais-tem-apenas-1-morador-14535208.ghtml>

Atualmente, observa-se um crescimento no número de pessoas morando sozinhas e uma redução no tamanho médio das famílias brasileiras. Essas transformações podem estar relacionadas a diversos fatores, como:

- mudanças econômicas;
- envelhecimento da população;
- aumento da independência financeira;
- mudanças culturais;
- crescimento urbano;
- novos modelos familiares.

Compreender essas mudanças é importante para:

- planejamento urbano;
- criação de políticas públicas;
- desenvolvimento habitacional;
- análise econômica;
- estudos populacionais.

2. Pré-Processamento:

Antes da análise, foi necessário realizar a limpeza da base de dados (IBGE – Instituto Brasileiro de Geografia e Estatística).

<https://sidra.ibge.gov.br/> - Anos 2022 e 2025.

[Tabela 6678: Domicílios, por número de moradores](#)

https://github.com/debora-rubio/mineracao_dados_moradias

As etapas realizadas foram:

- correção dos nomes das colunas;

- remoção da linha duplicada do cabeçalho;
- conversão dos dados para formato numérico;
- organização das variáveis;
- verificação de valores nulos.

Isso foi importante porque:

- dados bagunçados podem gerar resultados errados;
- algoritmos precisam de dados organizados;
- números precisam estar no formato correto.

A base utilizada contém informações sobre o número médio de moradores por domicílio em capitais brasileiras.

Os dados foram organizados em:

- 1 morador;
- 2 moradores;
- 3 moradores;
- 4 moradores;
- 5 moradores;
- 6 moradores ou mais.

Os anos analisados foram:

- 2022;
- 2025.

Além disso, foi realizada uma comparação específica com o Estado de São Paulo.

3. Objetivo do Trabalho:

Realizamos um comparativo específico entre os dados nacionais e os dados do Estado de São Paulo.

Os objetivos específicos foram:

- identificar padrões demográficos;
- comparar os perfis dos domicílios;
- encontrar grupos de Estados com características semelhantes;


- descobrir relações entre os dados de 2022 e 2025;
- aplicar técnicas de mineração de dados;
- interpretar os resultados de forma visual.

O estudo dos domicílios brasileiros é importante porque permite compreender como a sociedade está mudando ao longo do tempo e a busca das informações desses padrões, transforma os dados em conhecimento útil.

Nos últimos anos, diversos estudos do IBGE demonstraram:


- aumento de pessoas morando sozinhas;
- diminuição do tamanho médio das famílias;
- mudanças no perfil dos domicílios (cada vez menores por metro quadrado de construção).

Segue abaixo um gráfico com os dados nível Brasil e equiparado com o Estado de São Paulo do ano 2022, os quais técnicas utilizadas de mineração de dados para analisar os padrões de domicílios brasileiros de acordo com o número de moradores.



Observa-se que no ano de 2022 a nível Brasil, os Estados possuíam 11% dos domicílios com apenas 1 morador e no Estado de São Paulo, o percentual ficou em 6% destes domicílios com 1 morador.

Fazendo a mesma comparação no ano de 2025, nos Estados nível Brasil, ocorreu uma queda de 11% para 9% dos domicílios com apenas 1 morador e no Estado de São Paulo houve um acréscimo de 6% para 7%. (Gráfico abaixo).



Essas informações são importantes para:

- governos;
- empresas;
- pesquisadores;
- urbanistas;
- construtoras;
- setor imobiliário.

Porque envolve uma reestruturação organizacional das famílias, impactando em diversas áreas de nossa sociedade, tais como:

- saúde;
- educação;
- segurança;
- comércio;
- redes sociais;
- bancos;
- marketing;
- análise populacional.

Para obtenção dos dados, foram utilizadas duas técnicas principais:

- K-Means (agrupamento);
- Apriori (regras de associação).

4. K-Means:

O K-Means é um algoritmo de agrupamento.

Seu objetivo é separar dados semelhantes em grupos chamados clusters.

O algoritmo funciona de forma automática. Ele analisa os dados e tenta encontrar padrões parecidos, funciona como se estivéssemos separando objetos em caixas.

Por exemplo:

- uma caixa para famílias pequenas;
- uma caixa para famílias médias;
- uma caixa para famílias grandes.

Neste estudo, cada Estado foi associado a um grupo.

Os clusters receberam valores:

- Cluster 0; (onde se enquadrou o Estado de SP e mais 12 Estados);
- Cluster 1; (8 Estados);
- Cluster 2. (6 Estados).

Coeficiente de Silhueta	
Estados	Clusters
Rio Branco (AC)	0
Manaus (AM)	0
Fortaleza (CE)	0
João Pessoa (PB)	0
Maceió (AL)	0
Belo Horizonte (MG)	0
Rio de Janeiro (RJ)	0
São Paulo (SP)	0
Curitiba (PR)	0
Porto Alegre (RS)	0
Campo Grande (MS)	0
Goiania (GO)	0
Brasília (DF)	0

Coeficiente de Silhueta	
Estados	Clusters
Palmas (TO)	1
Natal (RN)	1
Recife (PE)	1
Aracaju (SE)	1
Salvador (BA)	1
Vitória (ES)	1
Florianópolis (SC)	1
Cuiabá (MT)	1

Coeficiente de Silhueta	
Estados	Clusters
Porto Velho (RO)	2
Boa Vista (RR)	2
Belém (PA)	2
Macapá (AP)	2
São Luís (MA)	2
Teresina (PI)	2

4.1 Clusters:

Clusters são grupos de dados semelhantes.

No projeto:

- Estados com comportamentos parecidos ficaram no mesmo grupo;
- Estados diferentes ficaram em grupos diferentes.

Cada cluster recebeu uma cor diferente nos gráficos.

Os resultados mostraram que alguns Estados apresentaram características semelhantes.

Exemplo:

- Estados com maior quantidade de pessoas morando sozinhas;
- Estados com famílias maiores;
- Estados com perfis médios.

4.2 Método do Cotovelo:

O Método do Cotovelo é utilizado para descobrir quantos grupos devem ser utilizados no K-Means.

O algoritmo testa diferentes quantidades de clusters.

Depois disso, é criado um gráfico.

O ponto onde a curva começa a diminuir menos intensamente é chamado de “cotovelo”.

Nesse ponto, considera-se que foi encontrado o número ideal de clusters.

No projeto, o valor escolhido foi:

- 3 clusters.




4.3 Coeficiente Silhueta:

O Coeficiente Silhueta é uma métrica utilizada para avaliar a qualidade dos agrupamentos.

Ele mede:

- o quanto os grupos estão separados;
- o quanto os dados são parecidos dentro do mesmo grupo.

No caso deste trabalho, a tela abaixo demonstra os resultados do K-Means gerado pelo algoritmo:



O gráfico do **K-Means** mostra os agrupamentos criados pelo algoritmo. Cada bolinha representa um município e cada cor representa um cluster diferente. Os municípios mais próximos possuem características semelhantes em relação ao percentual de domicílios com 1 morador entre 2022 e 2025. Os X pretos representam os centroides, que são os pontos centrais de cada grupo.

O gráfico do **coeficiente de silhueta** foi utilizado para avaliar a qualidade dos agrupamentos criados pelo K-Means. O eixo X representa a quantidade de clusters testados e o eixo Y representa o Coeficiente de Silhueta, que mede o nível de separação entre os grupos. O melhor equilíbrio foi encontrado com 3 clusters, apresentando um valor aproximado de 0,27, indicando

separação moderada entre os grupos. Para dados sociais e demográficos, esse valor é aceitável.

- próximo de 1 → grupos bem separados;
- próximo de 0 → grupos parcialmente misturados;
- valor negativo → agrupamento ruim.

4.4 Apriori:

O Apriori é um algoritmo de regras de associação. Seu objetivo é encontrar padrões que costumam acontecer juntos. O Apriori funciona melhor com categorias.

Por isso, os dados numéricos foram transformados nas categorias: Alto e Baixo.


Se o valor estava acima da média, recebeu o nome “Alto”, se estava abaixo da média, recebeu o nome “Baixo”.

O gráfico do Apriori apresenta as 10 regras de associação mais fortes encontradas pelo algoritmo. O eixo X representa o valor do Lift, que mede a força da relação entre os padrões. Já o eixo Y apresenta as regras identificadas. Quanto maior a barra, mais forte é a associação encontrada entre os tipos de domicílios.

Com a Regra da Associação:

Estados que apresentaram alto número de domicílios com 1 morador em 2022 também apresentaram valores altos em 2025.

Estados com aumento dos domicílios com apenas 1 morador, também reduziram os domicílios com 6 ou mais moradores.



4.5 Support (Suporte):

O suporte indica quantas vezes uma regra aparece nos dados.

Se existem 27 Estados e 6 Estados apresentam esse padrão, a porcentagem é $6/27 = 0.22$ ou 22%.

No caso, suporte = 0,22 - Significa que 22% dos Estados apresentaram aquele padrão.

Ou seja, aproximadamente 22% dos Estados com muitos domicílios com 1 morador, também possuem poucos domicílios com 6 moradores ou mais (apresentaram esse padrão).

Porque famílias pequenas aumentam; famílias grandes diminuem.

4.6 Confidence (Confiança):

A confiança mede o quanto uma regra costuma acontecer.

Se a confiança = 1.0, significa que sempre que a condição aconteceu, a regra também aconteceu. Confiança de 1 = 100% dos Estados seguem esse padrão.

4.7 Lift:

O Lift mede a força da associação entre duas características.

- Lift maior que 1 → associação positiva;
- Lift igual a 1 → sem relação;
- Lift menor que 1 → associação negativa.

No projeto, algumas regras apresentaram Lift próximo de: 3,85

Isso indica associações fortes entre determinadas características e relação significativa entre as variáveis.

LIFT (força da associação) 3,85 (muito forte, porque é maior que 1).

5. Análise final dos resultados:

Os resultados mostraram mudanças importantes no perfil dos domicílios brasileiros.

Observou-se:

- crescimento de domicílios com poucos moradores;
- continuidade de padrões entre 2022 e 2025;

- semelhanças entre determinados Estados.

O K-Means conseguiu identificar grupos de Estados com características semelhantes.

Já o Apriori encontrou associações fortes entre os padrões dos domicílios.

5.1. Comparação entre os Estados do Brasil e o Estado de São Paulo:

Os resultados indicaram que São Paulo apresenta comportamento semelhante a determinados grupos identificados pelo K-Means.

Também foi possível observar diferenças relacionadas ao número de moradores por domicílio, com tendências de redução na quantidade de moradores por domicílio.

6. Dificuldades encontradas:

Durante o desenvolvimento do projeto, algumas dificuldades foram encontradas:

- organização da base de dados;
- limpeza das colunas;
- interpretação dos algoritmos;
- compreensão das métricas;
- visualização dos gráficos.

Apesar disso, as ferramentas utilizadas permitiram desenvolver o projeto corretamente.

7. Conclusão:

A mineração de dados permitiu identificar padrões importantes relacionados aos domicílios brasileiros.

Os resultados mostraram:

- mudanças demográficas;
- crescimento de domicílios com apenas 1 morador;
- permanência de este padrão entre 2022 e 2025.

O algoritmo K-Means conseguiu separar Estados com características semelhantes.

Já o Apriori encontrou associações fortes entre os padrões analisados.

Ou seja, aproximadamente 22% dos Estados com muitos domicílios com 1 morador, também possuem poucos domicílios com 6 moradores ou mais (apresentaram esse padrão).

Porque famílias pequenas aumentam; famílias grandes diminuem.

Se existem 27 Estados e 6 Estados apresentam esse padrão, a porcentagem é $6/27 = 0.22$ ou 22%. O nível de Confiança de $1 = 100\%$ dos Estados seguem esse padrão e o LIFT (força da associação) 3,85 (muito forte, porque é maior que 1).

Os gráficos facilitaram a interpretação visual dos dados.

Além disso, o projeto permitiu compreender melhor o funcionamento das técnicas de mineração de dados.

A experiência também contribuiu para o aprendizado sobre:

- pré-processamento;
- agrupamento;
- associação;
- análise visual;
- interpretação de resultados.

8. Ferramentas utilizadas:

- Python;
- Jupyter Notebook;
- Pandas;
- Matplotlib;
- Seaborn;
- Scikit-Learn;
- Mlxtend.

9. Referências:

- IBGE – Instituto Brasileiro de Geografia e Estatística.
<https://sidra.ibge.gov.br/> - Anos 2022 e 2025.
[Tabela 6678: Domicílios, por número de moradores](#)
- Reportagem G1-Rede Globo do dia 17/04/2026 (4min20s):
<https://g1.globo.com/jornal-hoje/video/quase-um-em-cada-cinco-domicilios-do-pais-tem-apenas-1-morador-14535208.ghtml>
- Material da disciplina de Mineração de Dados (PDF's) – Prof. Angela Rosa Locateli de Godoy.